Exercise Week 04

GianAndrea Müller
mailto:muellegi@student.ethz

March 21, 2018

Time Schedule

- 3' Nachbesprechung
- 10' Dezimalzahlen im Binärsystem mit Übung
- 10' Fliesskommasystem $\mathcal{F}^*(2, 24, -126, 127)$
- 10' Tips zu Fliesskommazahlen
- 10' Funktionen
- 15' Pause
- 10' Funktionsdefinition- und deklaration
- 10' Pre- and post-conditions
- 10' Übung zu Funktionen

Learning Objectives

- Verständnis des Fliesskommasystems
- Nutzung von Funktionen

Nachbesprechung

- Kommentieren heisst nicht: Dasselbe in grün.
- Snippets: Verständnis zeigen!

Dezimalzahlen im Binärsystem

binär:	1	1	1	1	.	1	1	1
dezimal:	8	4	2	1		$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$

Dezimalzahlen im Binärsystem

x	d_i	$x - d_i$
1.934	1	0.934
9.34	9	0.34
3.4	3	0.4
4	4	0

x	b_i	$x - b_i$
1.9	1	0.9
1.8	1	0.8
1.6	1	0.6
1.2	1	0.2
0.4	0	0.8
1.6	1	0.6
	⋮	

$$1.1\overline{1100}$$

Exercise 4_1 $\sim$ 2'

Berechne die binäre Darstellung folgender Dezimalzahlen:

1. 0.25
2. 11.1

Solution 4_1

Lösung 1.

x	b_i	$x - b_i$
0.25	0	0.25
0.5	0	0.5
1	1	0

Lösung 2.

x	b_i	$x - b_i$
0.1	0	0.1
0.2	0	0.2
0.4	0	0.4
0.8	0	0.8
1.6	1	0.6
1.2	1	0.2
	$\vdots$	

Unser kleines 10bit Fliesskommasystem

Beschreibung von Fliesskommasystemen

$$\mathcal{F}(\underbrace{\beta}_{\text{Basis} \geq 2}, \overbrace{p}^{\text{Anzahl Stellen} \geq 1}, \underbrace{e_{min}, e_{max}}_{\text{Kleinster und Grösster Exponent}})$$

Unser kleines 10bit Fliesskommasystem

0000000000

- Vorkommastelle
- Nachkommastellen
- Exponent

$\mathcal{F}(2, 6, 0, 15)$

0000000000

- Vorkommastelle
- Nachkommastellen
- Exponent

Beispiele

$\underbrace{1.11111 \cdot 2^{15}}_{\text{Grösste Zahl}}$ $\underbrace{0.00001 \cdot 2^{0}}_{\text{Kleinste Zahl}}$

$\mathcal{F}(2, 6, -8, 7)$

0000000000

- Vorkommastelle
- Nachkommastellen
- Exponent

Beispiele

$\underbrace{1.11111 \cdot 2^{7}}_{\text{Grösste Zahl}}$ $\underbrace{0.00001 \cdot 2^{-8}}_{\text{Kleinste Zahl}}$

$\mathcal{F}^*(2, 6, -8, 7)$

0000000000

- Vorzeichenstelle
- Nachkommastellen
- Exponent

Beispiele

$\underbrace{+1.11111 \cdot 2^{7}}_{\text{Grösste Zahl}}$ $\underbrace{-1.11111 \cdot 2^{7}}_{\text{Kleinste Zahl}}$ $\underbrace{+1.00000 \cdot 2^{-8}}_{\text{Kleinste positive Zahl}}$

$\mathcal{F}^*(2, 6, -7, 7)$

$$0\,0000\,00000$$

- Vorzeichenstelle
- Nachkommastellen
- Exponent

Beispiele

$\underbrace{0\,0000\,00000}$	$\underbrace{0\,0000\,00001}$	$\underbrace{0\,0000\,00010}$	$\underbrace{0\,0000\,00011}$
Null	$+\infty$	$-\infty$	NaN

Exercise 4_2 $\sim$ 5'

Floating point systems following IEEE 754

- float (IEEE 745): $\mathcal{F}^*(2, 24, -126, 127)$
- double (IEEE 745): $\mathcal{F}^*(2, 53, -1022, 1023)$

1. What is the largest possible normalized single and double precision floating point number?
2. What is the smallest possible normalized single and double precision floatig point number?

Solution 4_2

Floating point systems following IEEE 754

1. Smallest normalized number: $2^{e_{min}}$
2. Largest normalized number, float:
   $+1.11111111111111111111111 \cdot 2^{127}$

$$\left(1 - \left(\frac{1}{\beta}\right)^{p}\right) \beta^{e_{max}+1}$$

Solution 4_2

$\mathcal{F}^*(2, 6, -7, 7)$

1. Grösste positive Zahl:

$$1.11111 \cdot 2^7$$

2. Das entspricht:

$$11111100$$

3. Grösste positive Zahl mit 8bit: $2^8 - 1$
4. Grösste positive Zahl mit 2bit: $2^2 - 1$
5. Mit variablen:

$$(\beta^{e_{max}+1} - 1) - (\beta^{e_{max}+1-p} - 1) = (\beta^{e_{max}+1} - \beta^{e_{max}+1-p})$$
$$= \left(1 - \left(\frac{1}{2}\right)^p\right) \beta^{e_{max}+1}$$

Tipps zu Fliesskommazahlen

```
1  //Kein Vergleich gerundeter Zahlen
2  double  a = 1.1;
3  if(100*a == 110) cout<<true<<endl;
4
5  //Keine Add. versch. grosser Zahlen
6  float a = 67108864.0f + 1.0f
7  //output: 67108864
8
9  //Keine Subtr. aehnlich grosser Zahlen
10 float x_0 = 0.2;
11 //represented as: 0.20000000298
12 float x_1 = 6*x_0 - 1; //is not 0.2
```

Funktionsdefinition und -deklaration

```
1  void g (...); //declaration of g
2
3  void f (...)
4  {
5     g(...);
6  }
7
8  void g (...) // definition of g
9  {
10    f(...);
11 }
```

PRE- und POST-Bedingungen

```
1  #include <cmath>
2
3  int main(){
4    // PRE: Value representing angle
       expressed in radians
5    // POST: Cosine of x
6    // double cos(double x);
7
8    double x = M_PI;
9    double result = cos(M_PI);
10 }
```